

EL HADJI MBOUP

DATA ENGINEER

ehmboup27@gmail.com • +33 7 44 13 45 00 • github.com/elmboup • linkedin.com/in/el-hadji-mboup

Data Engineer diplômé de Paris-Saclay et ingénieur informatique, avec une expérience concrète en Data Engineering et en production bancaire. J'ai travaillé sur la conception, l'industrialisation et l'observabilité de pipelines de données avec Python, SQL, Spark/PySpark, Kafka, Airflow, Data Quality, CI/CD et AWS.

EXPÉRIENCE PROFESSIONNELLE

Crédit Agricole Technologies & Services — Data Engineer · Stage de fin d'études

Mars 2026 - Sept. 2026

- Migré et optimisé des pipelines PySpark vers Spark 3.5 sur YARN en production : refactoring, sécurisation Kerberos et orchestration Oozie.
- Industrialisé un pipeline de prévision multi-entités : SQL avancé sur Teradata, backtesting, contrôles de qualité et déploiement en production.
- Automatisé les déploiements Dev / Homol / Prod via GitLab CI/CD et Ansible pour fiabiliser la mise en production.
- Mis en place une chaîne d'observabilité de bout en bout : Filebeat → Kafka → Logstash → Elasticsearch → Kibana.
- Contribué à l'industrialisation d'un assistant LLM : simulation d'API métier, injection de données, prompt engineering et benchmark RAG.

Environnement : Python • SQL • PySpark / Spark 3.5 • Teradata • Kafka • ELK • Hive / HDFS • YARN • Oozie • GitLab CI/CD • Ansible • AWS S3

Atos — Data Engineer · Alternance

Oct. 2023 - Mai 2025

- Développé des pipelines ETL Spark pour des données télécom massives et contribué à une plateforme d'observabilité avec Airflow, ELK, MinIO et Docker.
- Automatisé le monitoring de Data Quality avec dbt et Great Expectations, contribuant à une réduction de 30 % des erreurs de données.
- Contribué à la conception d'une plateforme Big Data selon une approche Modern Data Stack pour un cas d'usage BCEAO.
- Développé un chatbot LLM / RAG avec LangChain et PostgreSQL dans le cadre de cas d'usage Data & IA.

Environnement : Python • SQL • Spark • Airflow • dbt • Great Expectations • ELK • MinIO • Docker • PostgreSQL • LangChain

COMPÉTENCES CLÉS

Data Engineering : Python • SQL / PL-SQL • Spark / PySpark • ETL / ELT • dbt | **Data Platform** : Kafka • Airflow • Hive / HDFS • YARN • Databricks

Cloud & DevOps : AWS / S3 / Glue / Athena • Docker • GitLab CI/CD • Ansible • Linux | **Bases de données** : Teradata • PostgreSQL • Oracle • Snowflake • BigQuery

Qualité & Observabilité : Data Quality • Great Expectations • ELK • Data Observability | **Compléments** : Kubernetes • Terraform • RAG • LangChain • MLflow

PROJETS SÉLECTIONNÉS

- Modern Data Stack E-commerce — ingestion Airbyte, stockage Snowflake, transformations dbt et orchestration Dagster.
- AgriTech IoT — pipeline temps réel Kafka — Spark Streaming, orchestration Airflow et traitement de données capteurs.
- AWS Data Lake — données partitionnées sur S3, catalogue et ETL Glue, stockage Parquet, requêtes Athena, Data Quality et quarantaine.

FORMATION & CERTIFICATIONS

Université Paris-Saclay — Master 2 DataScale, 2025-2026 | Big Data, NoSQL, Cloud Computing, gestion de données à grande échelle

École Polytechnique de Thiès — Diplôme d'Ingénieur de Conception, Informatique & Télécommunications, 2020-2025

Certifications / accréditations : AWS Certified Cloud Practitioner • Apache Airflow Certification (Astronomer) • Databricks Fundamentals Accreditation • Google Cloud Professional Data Engineer Learning Path

Langues : Français C1 • Anglais C1