

EL HADJI MBOUP

DATA ENGINEER

ehmboup27@gmail.com • +33 7 44 13 45 00 • github.com/elmboup • linkedin.com/in/el-hadji-mboup

Data Engineer diplômé de Paris-Saclay et ingénieur informatique, avec plus de 2 ans d'expérience cumulée (alternance + stage), dont une expérience récente en production bancaire chez Crédit Agricole Technologies & Services. Conception, industrialisation et supervision de pipelines de données. Compétences clés : Python, SQL, Spark/PySpark, Kafka, Airflow, Data Quality, CI/CD et AWS.

EXPÉRIENCE PROFESSIONNELLE

Crédit Agricole Technologies & Services — Data Engineer · Stage de fin d'études Mars 2026 - Sept. 2026

- Migré et optimisé des pipelines PySpark vers Spark 3.5 sur YARN en production : refactoring, sécurisation Kerberos et orchestration Oozie.
- Industrialisé un pipeline de prévision multi-entités : SQL avancé sur Teradata, backtesting, contrôles de qualité et déploiement en production.
- Automatisé les déploiements Dev / Homol / Prod via GitLab CI/CD et Ansible pour fiabiliser la mise en production.
- Mis en place une chaîne d'observabilité de bout en bout : Filebeat → Kafka → Logstash → Elasticsearch → Kibana.
- Contribué à l'industrialisation d'un assistant LLM : simulation d'API métier, injection de données, prompt engineering et benchmark RAG.

Environnement : Python • SQL • PySpark / Spark 3.5 • Teradata • Kafka • ELK • Hive / HDFS • YARN • Oozie • GitLab CI/CD • Ansible • AWS S3

Atos — Data Engineer · Alternance Oct. 2023 - Mai 2025

- Développé des pipelines ETL Spark pour des données télécom massives et contribué à une plateforme d'observabilité avec Airflow, ELK, MinIO et Docker.
- Automatisé le monitoring de Data Quality avec dbt et Great Expectations, contribuant à une réduction de 30 % des erreurs de données.
- Contribué à la conception d'une plateforme Big Data selon une approche Modern Data Stack pour un cas d'usage BCEAO.
- Développé un chatbot LLM / RAG avec LangChain et PostgreSQL dans le cadre de cas d'usage Data & IA.

Environnement : Python • SQL • Spark • Airflow • dbt • Great Expectations • ELK • MinIO • Docker • PostgreSQL • LangChain

COMPÉTENCES CLÉS

Data Engineering : Python • SQL / PL-SQL • Spark / PySpark • ETL / ELT • dbt | Data Platform : Kafka • Airflow • Hive / HDFS • YARN • Databricks

Cloud & DevOps : AWS / S3 / Glue / Athena • Docker • GitLab CI/CD • Ansible • Linux | Bases de données : Teradata • PostgreSQL • Oracle • Snowflake • BigQuery

Qualité & Observabilité : Data Quality • Great Expectations • ELK • Data Observability | Compléments : Kubernetes • Terraform • RAG • LangChain • MLflow

PROJETS SÉLECTIONNÉS

- Modern Data Stack E-commerce — ingestion Airbyte, stockage Snowflake, transformations dbt et orchestration Dagster.
- AgriTech IoT — pipeline temps réel Kafka → Spark Streaming, orchestration Airflow et traitement de données capteurs.
- AWS Data Lake — données partitionnées sur S3, catalogue et ETL Glue, stockage Parquet, requêtes Athena, Data Quality et quarantaine.

FORMATION & CERTIFICATIONS

Université Paris-Saclay — Master 2 DataScale, 2025-2026 | Big Data, NoSQL, Cloud Computing, gestion de données à grande échelle

École Polytechnique de Thiès — Diplôme d'Ingénieur de Conception, Informatique & Télécommunications, 2020-2025

Certifications / accréditations : AWS Certified Cloud Practitioner • Apache Airflow Certification (Astronomer) • Databricks Fundamentals Accreditation • Google Cloud Professional Data Engineer Learning Path

Langues : Français C1 • Anglais C1